Clasificación de Osteoartritis mediante Inteligencia Artificial en Radiografías (OsteoClassAI)

Diego Esteban Zapata **2420211040**, Walter Andrés Cárdenas **2420211021**, Karol Julieta Rivera Gaitan **2420201069**

Electromedicina
Universidad de Ibagué

RESUMEN

La osteoartritis de rodilla (OA) afecta a millones de personas, siendo una causa significativa de dolor y discapacidad. El proyecto "OsteoClassAI" propone una solución basada en inteligencia artificial para automatizar el análisis de radiografías y clasificar la OA según la escala de Kellgren-Lawrence (KL). Utilizando una base de datos de 16,520 imágenes radiográficas de rodillas con distintos grados de OA, se entrenó un modelo basado en redes neuronales convolucionales (CNN). Este modelo distingue entre rodillas sanas, OA leve o moderada y OA severa.

A partir de 16,520 imágenes clasificadas por la escala de Kellgren-Lawrence, el modelo VGG19 alcanzó una precisión del 77.5%. Para ello, se implementaron técnicas como la normalización de imágenes, el aumento de datos y el entrenamiento en capas convolucionales. Además, se desarrolló una interfaz web que permite a los profesionales de la salud cargar radiografías y obtener diagnósticos automáticos.

El proyecto destaca la importancia de la normatividad para dispositivos médicos en Colombia y el cumplimiento de estándares internacionales para garantizar seguridad y eficacia. También resalta los beneficios de la IA en el diagnóstico médico, como la reducción de errores y la mayor precisión en el tratamiento de OA, planteando una solución accesible y eficiente para la población.

PALABRAS CLAVE: *Osteoartritis, Inteligencia Artificial, Kellgren-Lawrence, Automatización diagnóstica y Redes neuronales.*

Classification of Osteoarthritis by Artificial Intelligence on X-rays (OsteoClassAI)

ABSTRACT

Knee osteoarthritis (OA) affects millions of people, being a significant cause of pain and disability. The "OsteoClassAI" project proposes an artificial intelligence-based

solution to automate the analysis of x-rays and classify OA according to the Kellgren-Lawrence (KL) scale. Using a database of 16,520 radiographic images of knees with different degrees of OA, a model based on convolutional neural networks (CNN) was trained. This model distinguishes between healthy knees, mild or moderate OA, and severe OA.

From 16,520 images classified by the Kellgren-Lawrence scale, the VGG19 model achieved an accuracy of 77.5%. To achieve this, techniques such as image normalization, data augmentation and training in convolutional layers were implemented. Additionally, a web interface was developed that allows healthcare professionals to upload x-rays and obtain automatic diagnoses.

The project highlights the importance of regulations for medical devices in Colombia and compliance with international standards to guarantee safety and effectiveness. It also highlights the benefits of AI in medical diagnosis, such as the reduction of errors and greater precision in the treatment of OA, proposing an accessible and efficient solution for the population.

KEYWORDS: *Osteoarthritis, Artificial Intelligence, Kellgren-Lawrence, Diagnostic Automation and Neural Networks.*

Introducción

La osteoartritis (OA) es una enfermedad crónica común y una de las principales causas de dolor y discapacidad entre los adultos. En 2012, se estimó que 250 millones de personas en todo el mundo estaban afectadas por OA de rodilla. Con los efectos combinados del envejecimiento y el aumento de la obesidad, se estima que la proporción de la población de 45 años o más con OA de rodilla diagnosticada por un médico aumentará del 13,8% al 15,7%. La OA es un trastorno crónico complejo y el tratamiento terapéutico se caracteriza mejor por ser paliativo y reactivo [9]. A medida que estas articulaciones se degradan, ya no protegen los huesos de la articulación de la rodilla. Esto a su vez puede causar daño óseo, dolor y rigidez. Los síntomas empeoran con el tiempo y los médicos a menudo utilizan etapas para describir su progresión. [2]

La detección temprana y la correcta clasificación del grado de osteoartritis son esenciales para el manejo adecuado de la enfermedad, permitiendo intervenciones oportunas que pueden ralentizar su progresión y mejorar los resultados clínicos. La **escala de Kellgren-Lawrence (KL)** es un sistema de clasificación radiográfica utilizado para evaluar la severidad de la osteoartritis (OA) en las articulaciones, especialmente en la rodilla. Fue desarrollado por el doctor John Kellgren y el doctor J. Lawrence en la década de 1950 y se ha convertido en uno de los métodos más utilizados para clasificar la gravedad de la osteoartritis en estudios clínicos y radiográficos. [10]

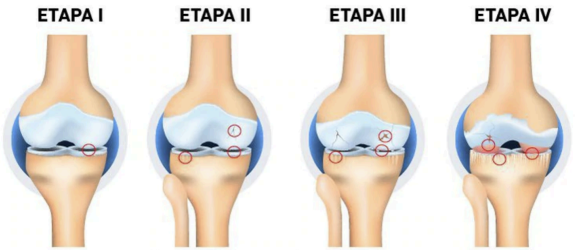


Figura 1: Clasificación de la artrosis de rodilla.
Fuente: https://www.drolivetto.com/news/patologia-rofilla-2/artrosis-de-rodilla-7

- **Etapa 1: Menor** - Una radiografía podría no revelar ningún daño, pero las protuberancias en el hueso llamadas osteofitos pueden ser una señal temprana de osteoartritis, al igual que pueden verse daños leves en el cartílago y estrechamiento en el espacio entre los huesos en la articulación.
- **Etapa 2: Leve** - Una radiografía posiblemente mostrará un estrechamiento del espacio en la articulación y espolones óseos. Puede haber algún daño menor, pero los huesos no se frotan ni se rozan entre sí, aunque los tejidos comenzarán a endurecerse.
- **Etapa 3: Moderada** - Una radiografía mostrará un estrechamiento visible en el espacio articular, cierto desarrollo de espolones óseos, algunos daños en el cartílago (adelgazando y descomponiéndose) y otros tejidos y una posible deformidad en el extremo de los huesos.
- **Etapa 4: Grave** - Una radiografía mostrará un estrechamiento severo del espacio articular, lo que provocará que los huesos se encuentren y se rocen, un desarrollo significativo de espolones óseos, daño visible en el cartílago (Erosionado total o casi totalmente) y una deformidad definida en los extremos de los huesos. Se recomienda cirugía.

En la última década, el campo de la inteligencia artificial (IA) ha mostrado un gran avance en la automatización del análisis de imágenes médicas. Es allí donde se encuentra**:**

IB Lab KOALA que es un dispositivo de software de procesamiento de imágenes radiológicas totalmente automatizado diseñado para ayudar a los médicos profesionales en la medición del ancho mínimo del espacio articular; y la gravedad de la osteoartritis radiográfica de rodilla según la clasificación de Kellgren y Lawrence de radiografías de rodilla en posición de pie y con flexión fija [8]. Este software es altamente utilizado por profesionales de la salud e investigadores es importante resaltar que este tiene una exactitud del 83%, este es ideal para automatizar la clasificación de la osteoartritis en el menor tiempo posible y permitiendo una segunda opinión asistida por la IA.

Por otro lado, **bone-finder** es una herramienta de software totalmente automática que permite delinear y segmentar estructuras óseas a partir de

radiografías 2D colocando un conjunto de puntos a lo largo del contorno del hueso o en puntos de referencia clave [6]. Esta herramienta permite observar la deformación por medio de su conjunto de puntos, con este método se tiene que para el 99% de las imágenes que se carga es el error es inferior a 1.0mm.

También está **Orthopred,** que es un software basado en inteligencia artificial diseñado para analizar imágenes médicas y detectar diversas afecciones ortopédicas, esta se centra principalmente en la evaluación de exámenes de resonancia magnética de rodilla. Aunque su capacidad de diagnóstico puede variar según la implementación y la versión del software [7]. Este Software es muy útil puesto que puede integrarse de forma rápida y facilita el flujo del trabajo clínico debido a que este se ejecuta cuando se está tomando la resonancia magnética.

Lenguajes como Python se destacan por su amplia adopción en proyectos de inteligencia artificial, gracias a su versatilidad y la disponibilidad de librerías especializadas como TensorFlow, Keras y PyTorch, que facilitan la implementación de redes neuronales y la integración de modelos de machine learning en aplicaciones prácticas. Las redes neuronales convolucionales pueden tener decenas o cientos de capas, y cada una de ellas aprende a detectar diferentes características de una imagen. Este algoritmo de aprendizaje se compone de cuatro partes principales que ayudan a imitar el funcionamiento del cerebro humano: Las Capas convolucionales, la unidad lineal rectificada (ReLU), las Capas de agrupamiento y las Capas totalmente conectadas. [4]

En los últimos años, se han desarrollado varios enfoques utilizando redes neuronales convolucionales para la clasificación y detección de la artrosis de rodilla. Estos modelos han sido entrenados para identificar y clasificar las imágenes de rayos X de la rodilla, permitiendo clasificarlas según el sistema de Kellgren-Lawrence, el estándar más empleado para evaluar la gravedad de esta enfermedad. Diversos estudios han explorado diversas arquitecturas de CNN, como VGG16, VGG19, ResNet50, YOLOv3 y EfficientNet-B5, y obtuvieron resultados significativos en la identificación y clasificación de la artrosis con elevados niveles de precisión.

La comercialización de un dispositivo médico como este en Colombia está sujeto a un riguroso proceso de regulación y cumplimiento normativo. El Instituto Nacional de Vigilancia de Medicamentos y Alimentos (INVIMA) es la entidad encargada de otorgar el registro sanitario necesario para que el producto pueda ser distribuido en el mercado. Este proceso implica la clasificación del dispositivo, la presentación de un expediente técnico detallado, y la validación clínica del software para garantizar su seguridad y eficacia. Además, es necesario cumplir con normativas internacionales como la ISO 13485 para sistemas de gestión de calidad y la IEC 62304 para el ciclo de vida del software, asegurando que el producto final no solo sea innovador, sino también seguro y confiable para su uso en entornos médicos. [1]

La implementación de una aplicación que maneje los datos médicos sensibles, como imágenes de radiografías, debe cumplir con estrictas normativas de protección de datos personales. En Colombia, la Ley 1581 de 2012 establece las directrices para el manejo de estos datos, asegurando que la privacidad de los pacientes sea respetada en todo momento. Además, la ciberseguridad juega un papel importante en la protección de la integridad del sistema y la confidencialidad de la información. [5]

Este panorama lleva a pensar que es necesario explorar un programa que tenga mayor exactitud que las soluciones existentes y que además, sea económico, eficiente, personalizable y accesible para una mayor cantidad de personas. Esta es la idea matriz que guía la propuesta que se presenta en este artículo.

Objetivos

La finalidad general de este artículo es desarrollar una aplicación basada en inteligencia artificial que, mediante el análisis automatizado de radiografías de rodilla, sea capaz de clasificar el grado de osteoartritis según la escala de Kellgren-Lawrence (KL). Se pretende concretamente:

a) Obtener o crear un banco de imágenes radiográficas de rodilla con osteoartritis, clasificadas según la escala Kellgren-Lawrence (KL), para entrenar y validar el software de análisis automatizado.
b) Crear y entrenar un modelo de inteligencia artificial capaz de identificar y segmentar con precisión la región de la articulación de la rodilla en radiografía.
c) Desarrollar un algoritmo que clasifique automáticamente las radiografías de rodilla en los grados de osteoartritis según la escala de Kellgren-Lawrence, desde KL 0 (sin signos de osteoartritis) hasta KL 4 (osteoartritis severa).
d) Evaluar su efectividad en la clasificación de osteoartritis con una precisión entre el 80% y el 95%.
e) Diseñar y validar una interfaz web que permita a los médicos interactuar con el sistema proporcionado acceso a la información almacenada.

Metodología

Se adquirió una base de datos de imágenes previamente clasificadas según su gravedad, obtenida de la plataforma Kaggle [3]. Las imágenes estaban clasificadas con base a la escala de Kellgren-Lawrence, se utilizaron 16520 imágenes de rodillas con artrosis, divididas en cinco grupos según esa clasificación: 6506 imágenes de grado 0, 2990 de grado 1, 4350 de grado 2, 2172 de grado 3 y 502 de grado 4. La base de datos fue dividida en tres conjuntos: el 70% de las imágenes se destinó para el entrenamiento del modelo con 11556 imágenes, el 20% para validación con

3312 imágenes y el 10% restante para testeo con 1652. Este proceso permitió garantizar que el modelo aprendiera, se ajustara y finalmente se evaluara con datos no vistos previamente.

Para simplificar la tarea de clasificación, las etiquetas originales fueron agrupadas en tres categorías: las imágenes clasificadas como 0 se mantuvieron como clase 0 (rodillas sanas), las etiquetas 1 y 2 se agruparon como clase 1 (gravedad leve o moderada) y las etiquetas 3 y 4 se combinaron en la clase 2 (gravedad severa). Este re-etiquetado permitió enfocar el modelo en distinguir entre niveles clínicamente relevantes de la enfermedad.

Dado que las redes neuronales convolucionales requieren imágenes en formato RGB, las radiografías originales, que estaban en escala de grises, fueron transformadas a imágenes con tres canales. Adicionalmente, todas las imágenes fueron redimensionadas a 224 x 224 píxeles para ser compatibles con los modelos estándar de visión por computadora. Y además, implementaron técnicas de aumento de datos (*data augmentation*), como rotaciones, cambios de brillo y zoom, con el objetivo de aumentar la variabilidad de las imágenes y mejorar la capacidad de aprendizaje del modelo.

El modelo fue desarrollado en el entorno de Visual Studio, utilizando librerías como TensorFlow y Keras. La arquitectura de la red neuronal convolucional incluyó capas convolucionales para detectar patrones locales, capas de *pooling* para reducir dimensiones manteniendo las características esenciales, y capas densas que finalmente permitieron clasificar las imágenes en las tres categorías definidas. Estas capas se diseñaron para capturar características específicas de las radiografías, como la distancia entre los huesos de la rodilla y la textura ósea, lo que es crucial para diagnosticar la osteoartritis.

Durante el entrenamiento, diversos modelos fueron evaluados con el conjunto de validación para ajustar los hiperparámetros y minimizar el sobreajuste, entrenando durante 50 epochs, teniendo que cuenta que se detuviera cuando dejara de aprender. Para su evaluación, se generó un reporte con una matriz de confusión, la precisión, la sensibilidad de cada modelo y la puntuación F1.

Finalmente, se desarrolló una interfaz de usuario que permite cargar radiografías directamente. A través de esta interfaz, el usuario puede obtener una clasificación automática que indica si la rodilla está sana, presenta una gravedad leve o moderada, o si sufre una gravedad severa de osteoartritis.

Resultados

De todos los modelos de aprendizaje automático encargados de hacer esta predicción, el que tuvo mejor desempeño fue la red neuronal convolucional VGG19, con 144 millones de parámetros.

Con el conjunto de datos de testeo, correspondiente al 20% de los datos, hubo una exactitud del 75%. Mientras que con el de validación, aquellos datos que el modelo nunca vio, fue del 77.14%.

Accuracy on test set: 0.7714
Classification Report:

	precision	recall	f1-score	support
0	0.76	0.81	0.79	672
1-2	0.73	0.70	0.72	671
3-4	0.88	0.84	0.86	293
accuracy			0.77	1636
macro avg	0.79	0.78	0.79	1636
weighted avg	0.77	0.77	0.77	1636

Figura 2. Reporte de clasificación del conjunto de datos de validación.
Fuente: Autor

Al observar la precisión por clase de los datos de validación, el modelo logró una precisión del 76% para el grado 0, clasificó correctamente 971 de las 1278 imágenes de esta categoría. Para el grado 1 (1-2), la precisión fué de 73%, con 1085 imágenes correctamente clasificadas de un total de 1486. Finalmente para el grado 2 (3-4), la precisión fué del 88%, con 482 de 548 imágenes correctamente clasificadas.

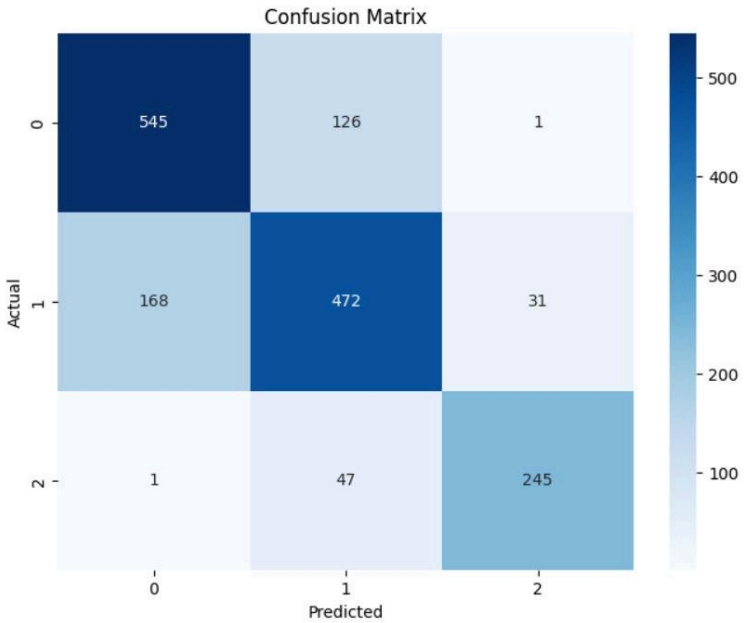


Figura 3. Matriz de confusión del conjunto de datos de validación.
Fuente: Autor

```
Accuracy on test set: 0.7497
Classification Report:
              precision    recall  f1-score   support

           0       0.73      0.79      0.75      1312
         1-2       0.74      0.69      0.72      1493
         3-4       0.85      0.82      0.84       515

    accuracy                           0.75      3320
   macro avg       0.77      0.77      0.77      3320
weighted avg       0.75      0.75      0.75      3320
```

Figura 4. Reporte de clasificación del conjunto de datos de testeo.
Fuente: Autor

Al observar la precisión por clase de los datos de testeo, el modelo logró una precisión del 73% para el grado 0, clasificó correctamente de las 656 imágenes de esta categoría. Para el grado 1 (1-2), la precisión fué de 74%, con 520 imágenes correctamente clasificadas de un total de 703. Finalmente para el grado 2 (3-4), la precisión fué del 85%, con 226 de 266 imágenes correctamente clasificadas.

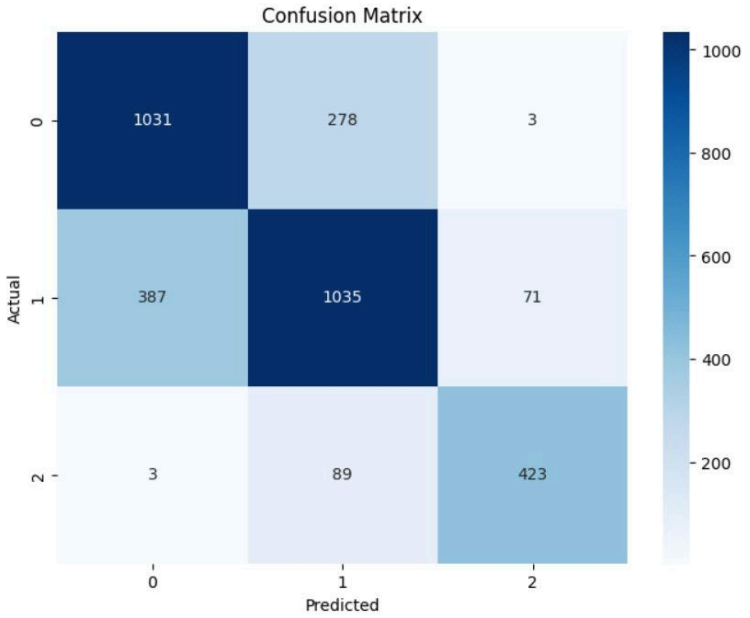


Figura 5. Matriz de confusión del conjunto de datos de testeo.
Fuente: Autor

La sensibilidad global del modelo fue del 77.5%, lo que demuestra su capacidad para identificar correctamente la mayoría de las imágenes positivas para artrosis de rodilla. Por último, la puntuación F1, que combina precisión y sensibilidad, también fué del 78%, esto confirma un buen equilibrio entre la precisión y la capacidad de recuperación del modelo. Finalmente, se diseñó una interfaz que permite al usuario cargar la imágen desde su dispositivo, mostrando a la izquierda la imágen original

cargada y a la derecha su versión procesada. Y en la parte inferior, se encuentra el resultado correspondiente (Clase 0, 1 o 2).

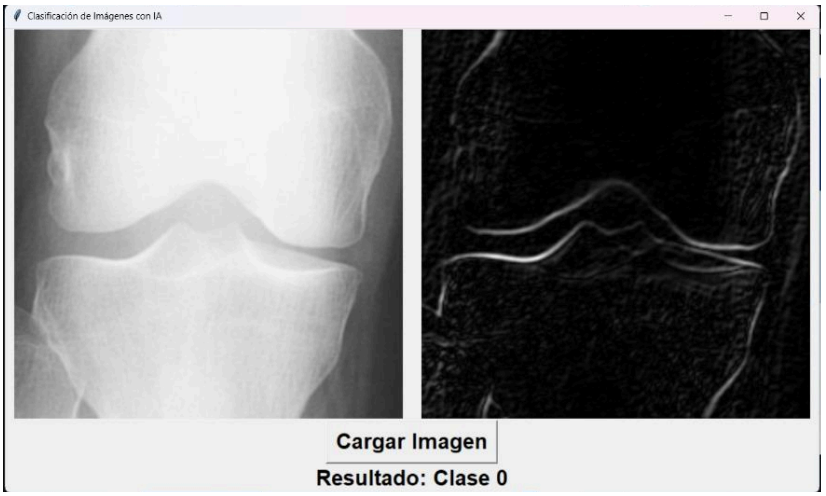


Figura 6. Interfaz final.
Fuente: Autor

Conclusión y discusión

La radiografía frontal ha sido durante años el método más utilizado para la clasificación diagnóstica de la artrosis de rodilla. No obstante, la interpretación de estas imágenes puede variar entre los evaluadores, lo que puede llevar a inconsistencias en la clasificación y en consecuencia, influir en las decisiones de tratamiento.

La implementación de estas tecnologías facilita la automatización del análisis de imágenes radiográficas. Este tipo de programa puede ser entrenado para identificar y clasificar automáticamente las imágenes de rodilla según la gravedad de la artrosis, utilizando como base el sistema de clasificación de Kellgren-Lawrence. Esto no solo mejora la eficiencia del diagnóstico, sino que también contribuye a lograr una mayor precisión, reduciendo la variabilidad entre evaluadores y proporcionando apoyo en la toma de decisiones clínicas.

La implementación de técnicas de procesamiento de imágenes fue crucial para mejorar la calidad de las entradas al modelo, especialmente en la detección y análisis del cartílago. Herramientas como la segmentación de la región de interés y la normalización de contraste ayudaron a resaltar las características relevantes para la clasificación, minimizando el impacto de variaciones externas (como iluminación y resolución).

Referencias bibliográficas

[1] Dispositivos médicos y equipos biomédicos. Gov.co. de https://www.minsalud.gov.co/salud/MT/Paginas/dispositivos-medicos-equipos-biomedicos.aspx

[2] Higuera, V. (2021, 7 de octubre). Artrosis de rodilla: Etapas, diagnóstico y tratamiento. Medical and health information | MedicalNewsToday. Recuperado de https://www.medicalnewstoday.com/articles/es/artrosis-de-rodilla

[3] Tiwari, S. (s. f.). Knee osteoarthritis dataset with severity grading. Kaggle. Recuperado de https://www.kaggle.com/datasets/shashwatwork/knee-osteoarthritis-dataset-with-severity

[4] Kelta, Z. (2024, abril). Introducción a las redes neuronales convolucionales (CNN). datacamp. Recuperado de https://www.datacamp.com/es/tutorial/introduction-to-convolutional-neural-networks-cnns

[5] Ley 1581 de 2012 - Gestor Normativo. Función Pública. Recuperado de https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981

[6] Lindner, C. BoneFinder®. Recuperado de https://bone-finder.com/

[7] OrthoPred. Recuperado de https://orthopred.com/

[8] Paixao, T., Eckstein, F., Wirth, W., & Nevitt, M. (2020). Una nueva métrica cuantitativa para el ancho del espacio articular: datos de la Osteoarthritis Initiative (OAI). Osteoarthritis Cartilage, 28(8), 1055–1061.

[9] Roemer, F. W., Eckstein, F., Guermazi, A., & Wirth, W. (2020). Estado del arte: imágenes de osteoartritis: revisitado en 2020. Radiology, 296(1), 5–21.

[10] Vista de correlación de la escala de Kellgren-Lawrence con la clasificación de Outerbridge en pacientes con gonalgia crónica. (s.f.). Revista Colombiana de Ortopedia y Traumatología. Recuperado de https://www.revistaortopediaytraumatologia.com